Prediksi Customer Churn Menggunakan Ensemble Learning (XGBoost & RSF) dengan Penanganan Imbalanced Data

Ester Yunita Nainggolan (23083010039)
Erna Novita Anggie (23083010038)



Machine Learning 2

Latar Belakang



Persaingan dalam industri telekomunikasi mendorong perusahaan untuk mempertahankan pelanggan sekaligus mengurangi risiko kehilangan pelanggan (customer churn). Churn terjadi ketika pelanggan menghentikan penggunaan layanan, yang dapat berdampak pada penurunan pendapatan dan meningkatnya kebutuhan untuk memperoleh pelanggan baru. Oleh karena itu, identifikasi pelanggan yang berpotensi melakukan churn menjadi salah satu aspek penting dalam pengelolaan hubungan pelanggan.

Permasalahan : Customer churn menjadi tantangan industri telekomunikasi karena kehilangan pelanggan dapat memengaruhi pendapatan dan keberlanjutan bisnis.

Mengapa Perlu Dilakukan?

- Churn Rate di dataset 26.5% (kelas minoritas)
- Class Imbalance (Model cenderung bias ke “No Churn”) dan Multi Perspektif (perlu klasifikasi dan survival analysis)

Pendekatan Solusi

- Ensemble Learning: Combined XGBoost (Gradient Boosting) dan Random Survival Forest (Survival & Risk Scoring).

- Penanganan Class Imbalance: Menerapkan class weighting, SMOTE, serta threshold tuning optimal.



Dataset & Eksplorasi Awal

Dataset : Dataset Telco Customer Churn
Jumlah Data : 7.043 Pelanggan
Jumlah Kolom : 21 Fitur

Distribusi Kelas Churn

Status Churn	
No	5174
Yes	1869

Missing Value

	Jumlah Missing	Persentase Missing (%)
TotalCharges	11	0.16

XGBOOST (19 Fitur)

Numerik :
- SeniorCitizen, tenure, MonthlyCharges, TotalCharges

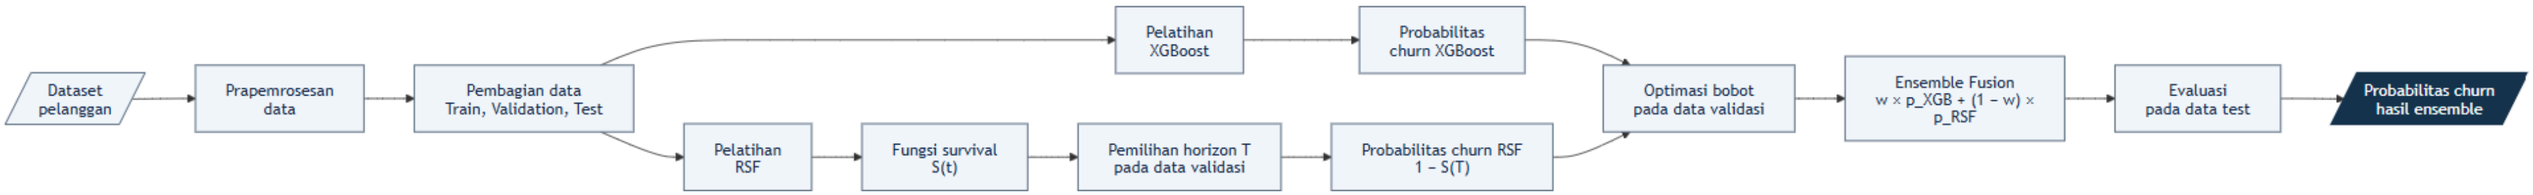
Kategori :
- gender, Partner, Dependents, PhoneService, MultipleLines, InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies, Contract, PaperlessBilling, PaymentMethod

RADOM SEARCH FOREST (17 Fitur)

Numerik :
- SeniorCitizen, MonthlyCharges

Kategori :
- gender, Partner, Dependents, PhoneService, MultipleLines, InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies, Contract, PaperlessBilling, PaymentMethod

FLowchart


Dataset pelanggan
Prapemrosesan data
Pembagian data Train, Validation, Test
Pelatihan XGBoost
Probabilitas churn XGBoost
Pelatihan RSF
Fungsi survival S(t)
Pemilihan horizon T pada data validasi
Probabilitas churn RSF 1 – S(T)
Optimasi bobot pada data validasi
Ensemble Fusion w × p_XGB + (1 – w) × p_RSF
Evaluasi pada data test
Probabilitas churn hasil ensemble

Penanganan Imbalanced Data



Perbandingan Strategi di Validation Set

- Pembobotan Kelas : scale_post_weight = 1
- Oversampling : SMOTE pada data training

Baseline (scale_pos_weight = 1)	Tanpa Pembobotan
Class Weighted (scale_pos_weight ≈ 2.77)	Menyeimbangkan penalti error berdasarkan rasio kelas.
SMOTE	Oversampling sintetik pada data training.

Hasil Pemilihan Strategi

- Kandidat bobot kelas : 1,0 2,77 4,0
- Bobot kelas terbaik : 4,0
- SMOTE menyeimbangkan training menjadi 3.311

Average Precision Validasi :

- Pembobotan kelas: 0,6757
- SMOTE : 0,6506

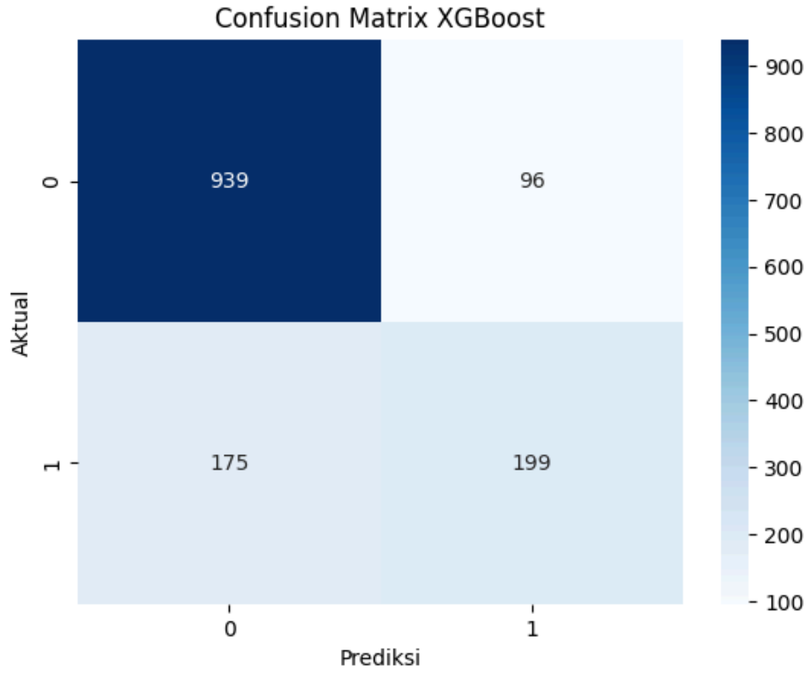
XGBoost (Gradient Boosting untuk Klasifikasi Churn)

Hyperparameter Tuning:

n_estimators	[300, 500]
max_depth	[3, 4, 5]
learning_rate	[0.03, 0.05]
scale_pos_weight	[1.0, 2.77, 4.0]

Evaluasi:

```
Accuracy : 0.8076650106458482
Precision: 0.6745762711864407
Recall   : 0.5320855614973262
F1-score : 0.5949177877428998
ROC-AUC  : 0.8482755948229093
```



Best Params (Parameter Terbaik):

learning_rate: 0.03
max_depth: 3
n_estimators: 300
scale_pos_weight: 4.0

Random Survival Forest

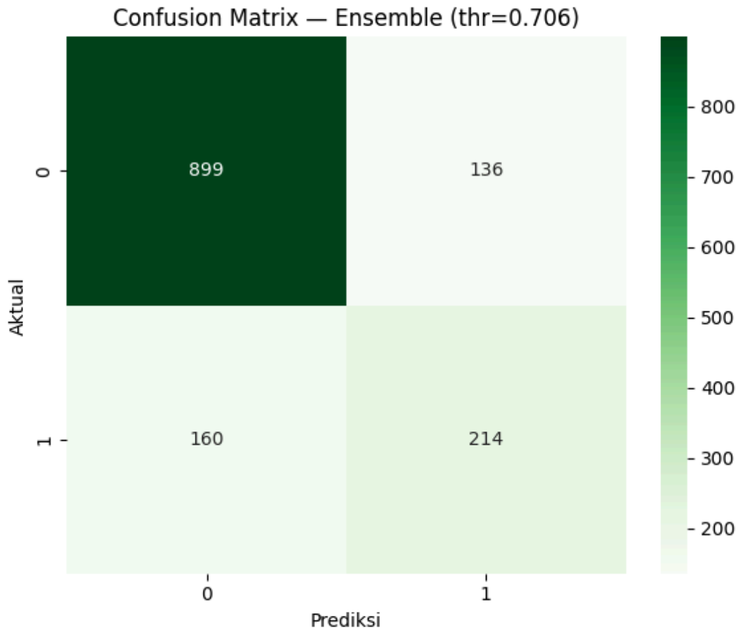
Target Variabel:

- event = Status Churn (Yes/No)
- time = Durasi berlangganan (tenure)

- Performa Diskriminasi Tinggi (C-Index = 0.8404): Model RSF memiliki akurasi 84.04% dalam mengurutkan tingkat risiko churn pelanggan berdasarkan durasi masa langganan (tenure).
- Tingkat Kesalahan Sangat Rendah (IBS = 0.0971): Prediksi probabilitas survival S(t) pada interval 12, 24, hingga 36 bulan terbukti konsisten dan sangat akurat (error < 10%).
- Integrasi Fitur RSF Risk Score: Setiap pelanggan menghasilkan nilai RSF_Risk_Score yang akan digunakan sebagai variabel input bersama probabilitas XGBoost untuk pemodelan K-Means Clustering.
- Hyperparameter: n_estimators=300, min_samples_leaf=10, max_features="sqrt"

Metrik / Fitur Output	Nilai / Contoh Data	Keterangan & Insight Praktis
C-Index (Concordance Index)	**0.8404**	Kemampuan diskriminasi model sangat tinggi (~84%) dalam membedakan urutan risiko churn pelanggan berdasarkan waktu bertahan.
Integrated Brier Score (IBS)	0.0971	Mengukur tingkat kesalahan prediksi fungsi survival S(t). Nilai mendekati 0 menunjukkan prediksi yang sangat akurat.
Brier Score per Horizon	12 BKN: 0.0936 24 BKN: 0.0982 36 BKN: 0.0985	Menunjukkan stabilitas akurasi prediksi probabilitas survival yang sangat konsisten pada rentang waktu 1, 2, hingga 3 tahun.
Top High-Risk Customer (Contoh)	ID: 8752-STIVR Tenure: 4.0 Bulan Risk Score: 140.94	Pelanggan dengan tenure singkat dan skor risiko relatif sangat tinggi yang teridentifikasi berisiko mengalami churn paling awal.

Ensemble Fusion (XGB + RSF)



Late fusion: menggabungkan prediksi XGBoost dan RSF pada level probabilitas

XGBoost: menghasilkan probabilitas churn secara langsung.

RSF: menghasilkan probabilitas churn dengan horizon terpilih 48 bulan.

Bobot optimal: 70% XGBoost + 30% RSF, dipilih berdasarkan ROC-AUC pada data validasi.

```
======================================
EVALUASI FINAL (threshold = 0.706)
======================================
Accuracy  : 0.7899
Precision : 0.6114
Recall    : 0.5722
F1-score  : 0.5912
ROC-AUC   : 0.8398
```

Evaluasi Perbandingan

```
============================================================
LANGKAH 3: Perbandingan model pada VALIDATION (ROC-AUC)
============================================================
  XGB only  : 0.8527
  RSF only  : 0.8438
  Fusion    : 0.8567
```

customerID	Churn_Aktual	Prob_XGB	Prob_RSF	Prob_Ensemble	Prediksi_Ensemble
4376-KFVRS	No Churn	0.052740	0.001063	0.037237	No Churn
2754-SDJRD	No Churn	0.917025	0.559783	0.809852	Churn
9917-KWRBE	No Churn	0.232890	0.038153	0.174469	No Churn
0365-GXEZS	No Churn	0.671588	0.503718	0.621227	No Churn
9385-NXKDA	No Churn	0.042879	0.005534	0.031675	No Churn
4686-UXDML	No Churn	0.858317	0.617814	0.786166	Churn
2227-JRSJX	No Churn	0.773054	0.428844	0.669791	No Churn
4830-FAXFM	No Churn	0.346757	0.213126	0.306667	No Churn
1830-IPXVJ	No Churn	0.027651	0.003003	0.020256	No Churn
4690-LLKUA	Churn	0.679228	0.856819	0.732505	Churn

Kesimpulan

Hasil penelitian menunjukkan bahwa model ensemble XGBoost dan Random Survival Forest menghasilkan ROC-AUC validasi sebesar 0,8567, sedikit lebih tinggi dibandingkan XGBoost sebesar 0,8527 dan C-Index RSF sebesar 0,8438. Pada data test, ensemble memperoleh ROC-AUC 0,8398, akurasi 78,99%, dan recall churn 57,22%, yang menunjukkan bahwa model masih belum mampu mendeteksi seluruh pelanggan yang benar-benar melakukan churn. Penggunaan class weighting juga memberikan Average Precision validasi sebesar 0,6757, lebih tinggi daripada SMOTE sebesar 0,6506, sehingga dipilih sebagai strategi penanganan ketidakseimbangan kelas. Meskipun demikian, penelitian ini memiliki keterbatasan karena dataset tidak menyediakan tanggal churn secara eksplisit, sehingga penggunaan tenure sebagai durasi survival merupakan asumsi dan hasil RSF perlu diinterpretasikan secara hati-hati. Selain itu, peningkatan performa ensemble dibandingkan XGBoost masih relatif kecil, sehingga kompleksitas penggabungan model perlu dipertimbangkan.

Thank You