Prediksi Customer Churn Menggunakan Ensemble Learning (XGBoost & RSF) dengan Penanganan Imbalanced Data

Ester Yunita Nainggolan (23083010039)
Erna Novita Anggie (23083010038)

Kelompok 8



Machine Learning 2

Latar Belakang



Persaingan dalam industri telekomunikasi mendorong perusahaan untuk mempertahankan pelanggan sekaligus mengurangi risiko kehilangan pelanggan (customer churn). Churn terjadi ketika pelanggan menghentikan penggunaan layanan, yang dapat berdampak pada penurunan pendapatan dan meningkatnya kebutuhan untuk memperoleh pelanggan baru. Oleh karena itu, identifikasi pelanggan yang berpotensi melakukan churn menjadi salah satu aspek penting dalam pengelolaan hubungan pelanggan.

Permasalahan : Customer churn menjadi tantangan industri telekomunikasi karena kehilangan pelanggan dapat memengaruhi pendapatan dan keberlanjutan bisnis.

Mengapa Perlu Dilakukan?

- Churn Rate di dataset 26.5% (kelas minoritas)
- Class Imbalance (Model cenderung bias ke “No Churn”) dan Multi Perspektif (perlu klasifikasi dan survival analysis)

Pendekatan Solusi

- Ensemble Learning: Combined XGBoost (Gradient Boosting) dan Random Survival Forest (Survival & Risk Scoring).
- Penanganan Class Imbalance: Menerapkan class weighting, SMOTE, serta threshold tuning optimal.
- Segmentasi Risiko: Mengelompokkan profil pelanggan (Low, Medium, High Risk) menggunakan K-Means Clustering.



Dataset & Eksplorasi Awal

Dataset : Dataset Telco Customer Churn
Jumlah Data : 7.043 Pelanggan
Jumlah Kolom : 21 Fitur

Distribusi Kelas Churn

Status Churn	
No	5174
Yes	1869

Missing Value

	Jumlah Missing	Persentase Missing (%)
TotalCharges	11	0.16

XGBOOST (19 Fitur)

Numerik :
- SeniorCitizen, tenure, MonthlyCharges, TotalCharges

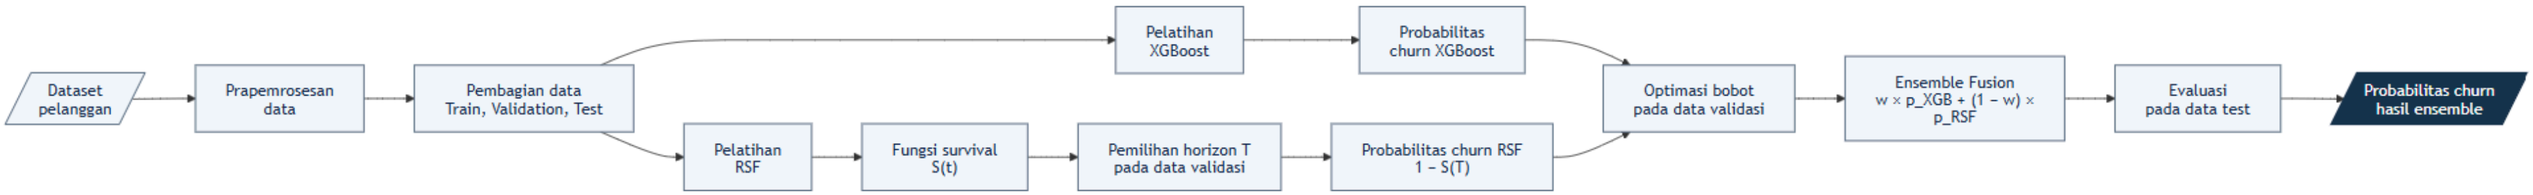
Kategori :
- gender, Partner, Dependents, PhoneService, MultipleLines, InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies, Contract, PaperlessBilling, PaymentMethod

RADOM SEARCH FOREST (17 Fitur)

Numerik :
- SeniorCitizen, MonthlyCharges

Kategori :
- gender, Partner, Dependents, PhoneService, MultipleLines, InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies, Contract, PaperlessBilling, PaymentMethod

FLowchart


Dataset pelanggan
Prapemrosesan data
Pembagian data Train, Validation, Test
Pelatihan XGBoost
Probabilitas churn XGBoost
Pelatihan RSF
Fungsi survival S(t)
Pemilihan horizon T pada data validasi
Probabilitas churn RSF 1 – S(T)
Optimasi bobot pada data validasi
Ensemble Fusion w × p_XGB + (1 – w) × p_RSF
Evaluasi pada data test
Probabilitas churn hasil ensemble

Penanganan Imbalanced Data



Perbandingan Strategi di Validation Set

- Pembobotan Kelas : scale_post_weight = 1
- Oversampling : SMOTE pada data training

Baseline (scale_pos_weight = 1)	Tanpa Pembobotan
Class Weighted (scale_pos_weight ≈ 2.77)	Menyeimbangkan penalti error berdasarkan rasio kelas.
SMOTE	Oversampling sintetik pada data training.

Hasil Pemilihan Strategi

- Kandidat bobot kelas : 1,0 2,77 4,0
- SMOTE menyeimbangkan training menjadi 3.311

Average Precision Validasi :

- Pembobotan kelas: 0,6757
- SMOTE : 0,6506

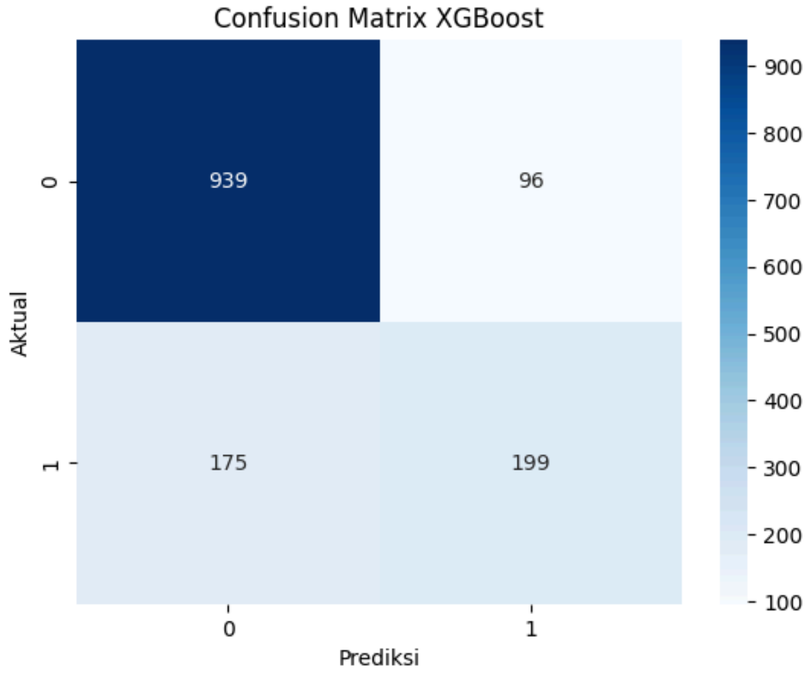
XGBoost (Gradient Boosting untuk Klasifikasi Churn)

Hyperparameter Tuning:

n_estimators	[300, 500]
max_depth	[3, 4, 5]
learning_rate	[0.03, 0.05]
scale_pos_weight	[1.0, 2.77, 4.0]

Evaluasi:

```
Accuracy : 0.8076650106458482
Precision: 0.6745762711864407
Recall   : 0.5320855614973262
F1-score : 0.5949177877428998
ROC-AUC  : 0.8482755948229093
```



Best Params (Parameter Terbaik):
{'learning_rate': 0.03, 'max_depth': 3,
'n_estimators': 300, 'scale_pos_weight': 4.0}

Kelebihan Model:

- Mampu menangani pola non-linear dan interaksi antarfitur yang kompleks.
- Robust (tahan) terhadap outlier.
- Memiliki built-in regularization untuk mencegah overfitting.

Random Survival Forest

Ensemble Bagging untuk survival analysis (memodelkan risiko dan waktu terjadinya event).

Perbedaan dengan Klasifikasi Biasa:

- Memprediksi waktu sampai churn (bukan hanya status biner "akan churn atau tidak").
- Mampu menangani censoring (pelanggan yang belum churn selama masa observasi).

Target Variabel:

- event = Status Churn (Yes/No)
- time = Durasi berlangganan (tenure)

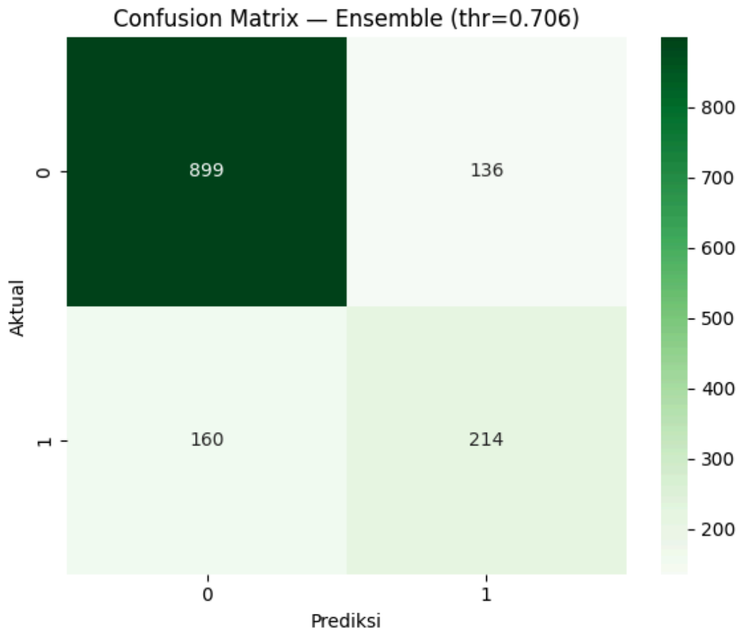
Hyperparameter:

- n_estimators = 300
- min_samples_leaf = 10
- max_features = "sqrt"

Output Model: Fungsi survival S(t), di mana probabilitas pelanggan melakukan churn dihitung sebagai 1 - S(T).

Metrik Evaluasi: Concordance Index (C-index) — analog dari AUC khusus untuk analisis survival.

Ensemble Fusion (XGB + RSF)



Late fusion: menggabungkan prediksi XGBoost dan RSF pada level probabilitas

XGBoost: menghasilkan probabilitas churn secara langsung.

RSF: menghasilkan probabilitas churn melalui $1-S(T)$, dengan horizon terpilih 48 bulan.

Bobot optimal: 70% XGBoost + 30% RSF, dipilih berdasarkan ROC-AUC pada data validasi.

```
======================================
EVALUASI FINAL (threshold = 0.706)
======================================
Accuracy  : 0.7899
Precision : 0.6114
Recall    : 0.5722
F1-score  : 0.5912
ROC-AUC   : 0.8398
PR-AUC    : 0.6445
```

Kesimpulan

Ensemble menggabungkan 70% XGBoost dan 30% RSF, berdasarkan pemilihan bobot pada data validasi.

ROC-AUC validasi meningkat menjadi 0,8567, dibandingkan XGBoost 0,8527 dan RSF 0,8438.

Pada data test, model memperoleh ROC-AUC 0,8398, akurasi 78,99%, dan recall churn 57,22%.

Prediksi dapat digunakan sebagai pendukung penentuan prioritas pelanggan untuk program retensi, bukan sebagai keputusan tunggal.

Thank You

Implementasi Pertahanan Berlapis



Manajemen Akses dan Identitas

Keamanan Data Bisnis

Melindungi Aset Informasi Dari Ancaman Pihak Luar

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Donec quis erat et quam iaculis faucibus at sit amet nibh. Vestibulum dignissim lectus in ligula rhoncus, et bibendum risus dictum. Pellentesque condimentum arcu id dapibus tempor. Pellentesque venenatis nec magna nec finibus. Sed ut perspiciatis unde omnis iste natus error sit voluptatem accusantium doloremque laudantium, totam rem aperiam, eaque ipsa quae ab illo inventore veritatis et quasi architecto beatae vitae dicta sunt explicabo.

Penanganan Imbalanced Data



Membaca Peluang Masa Depan Berdasarkan Data Historis

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Donec quis erat et quam iaculis faucibus at sit amet nibh. Vestibulum dignissim lectus in ligula rhoncus, et bibendum risus dictum.

Pemanfaatan Model Statistik dan Machine Learning

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Donec quis erat et quam iaculis faucibus at sit amet nibh. Vestibulum dignissim lectus in ligula rhoncus, et bibendum risus dictum.

Pengantar Analisis Data

Mengapa Data Penting Bagi Perусahaan Modern

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Donec quis erat et quam iaculis faucibus at sit amet nibh. Vestibulum dignissim lectus in ligula rhoncus, et bibendum risus dictum. Pellentesque condimentum arcu id dapibus tempor. Pellentesque venenatis nec magna nec finibus. Sed ut perspiciatis unde omnis iste natus error sit voluptatem accusantium doloremque laudantium, totam rem aperiam, eaque ipsa quae ab illo inventore veritatis et quasi architecto beatae vitae dicta sunt explicabo.

